

NAFAD PAY

Architecture AWS — Early Stage (MVP)

Groupe 4 — Analytics & BI

Stack : PostgreSQL 16 · Metabase · Docker · AWS eu-west-3 (Paris)

1. Contexte & Objectif

NAFAD PAY est un système fictif de paiement mobile mauritanien. Le Groupe 4 est responsable de la couche Analytics & BI : construction du Data Warehouse, chargement des données et production des dashboards décisionnels pour le Directeur Général.

Cette documentation couvre l'infrastructure AWS Early Stage (MVP), dimensionnée pour un volume initial de 100 000 transactions et 10 000 utilisateurs. Elle inclut les schémas détaillés de l'architecture réseau, du flux de données et du pipeline ETL.

2. Choix de la Région AWS — eu-west-3 (Paris)

2.1 Comparaison des régions

Région	Distance (km)	Latence estimée	Décision
eu-west-3 Paris 	~4 000	40–60 ms	RETENU
af-south-1 Le Cap	~7 000	120–150 ms	Rejeté — trop loin
eu-west-1 Dublin	~4 300	50–70 ms	Alternative acceptable
Hetzner fsn1 Falkenstein	~4 500	50–70 ms	Pas de RDS managé

2.2 Justifications ADR

- › Latence optimale : Paris est la région AWS la plus proche de Nouakchott (~4 000 km, 40–60 ms).
- › Services managés complets : RDS, Secrets Manager, VPC disponibles dès le MVP.
- › af-south-1 Le Cap rejeté : 7 000 km, latence 3× supérieure, moins de services managés.
- › Hetzner rejeté : absence de RDS managé, complexité opérationnelle accrue sans valeur ajoutée.

3. Vue d'Ensemble de l'Architecture

3.1 Composants du MVP

Service	Instance / Config	Rôle
RDS PostgreSQL 16	db.t3.medium	Data Warehouse — subnet privé — backup 7 jours
EC2 Metabase	t3.medium — Amazon Linux 2023	Dashboard BI — subnet public — SSM Session Manager
S3 Standard	Bucket Standard	Stockage CSV staging (pipeline ETL)
Secrets Manager	1 secret	Mot de passe RDS — rotation manuelle
VPC	10.0.0.0/16	Réseau isolé — 1 subnet public + 1 subnet privé

4. Architecture Réseau — VPC et Isolation

4.1 Logique de segmentation réseau

Le VPC 10.0.0.0/16 est divisé en deux sous-réseaux distincts selon le principe de moindre exposition. Chaque composant est placé dans le sous-réseau correspondant à son niveau d'exposition requis.

Règle fondamentale de sécurité réseau

Tout composant qui n'a pas besoin d'être accessible depuis internet est placé dans le subnet privé. RDS ne reçoit jamais de connexion depuis internet — uniquement depuis l'EC2 via le Security Group.




Figure 1 — Logique réseau : qui peut parler à qui dans le VPC NAFAD PAY

4.2 Règles des Security Groups

Security Group	Règle Inbound	Règle Outbound	Justification
SG-EC2-Metabase	TCP 443 depuis 0.0.0.0/0	TCP 5432 vers SG-RDS	HTTPS public + accès BD privé
SG-RDS-PostgreSQL	TCP 5432 depuis SG-EC2	Aucune	Accès exclusif depuis l'EC2

4.3 SSM Session Manager — Administration sans SSH

L'accès administrateur à l'EC2 se fait via AWS SSM Session Manager, sans ouvrir le port 22 (SSH). Cela réduit la surface d'attaque et supprime la gestion des clés SSH.

- › Port 22 fermé : aucun accès SSH direct depuis internet.
- › Sessions chiffrées via SSM : accès auditable depuis la console AWS.
- › IAM-based : les permissions d'accès sont gérées via les rôles IAM, pas des clés.

5. Flux d'une Requête — Du Navigateur au Data Warehouse

5.1 Parcours complet d'une requête dashboard

Lorsque le Directeur Général ouvre le dashboard Metabase, voici exactement ce qui se passe, étape par étape :

Flux d'une requête — Du navigateur au Data Warehouse




Figure 2 — Flux d'une requête du Directeur Général jusqu'au Data Warehouse RDS

5.2 Détail des 5 étapes

Ét ap e	Composant	Action	Protocole
1	Navigateur DG	Ouvre https://[IP-EC2]:443	HTTPS/TLS
2	Security Group EC2	Filtre : accepte port 443, rejette tout autre port	AWS SG Rule
3	EC2 Metabase	Génère la requête SQL analytique · Récupère mdp dans Secrets Manager	HTTP interne
4	Security Group RDS	Autorise 5432 uniquement depuis SG-EC2	AWS SG Rule
5	RDS PostgreSQL 16	Exécute le SQL · Retourne les données JSON à Metabase	PostgreSQL

5.3 Pourquoi le mot de passe n'est-il jamais en clair ?

Metabase ne stocke pas le mot de passe RDS dans sa configuration. À chaque démarrage, il appelle l'API AWS Secrets Manager pour récupérer le secret chiffré. Le secret n'est jamais dans un fichier `.env`, un repo Git, ou une variable d'environnement exposée.

6. Pipeline ETL — Des Données Brutes au Data Warehouse

6.1 Vue d'ensemble du pipeline

Le pipeline ETL transforme les fichiers CSV déposés dans S3 par le Groupe 3 en tables structurées dans le Data Warehouse RDS. Il est entièrement orchestré par Docker Compose en 9 scripts SQL séquentiels.




Figure 3 — Pipeline ETL : des fichiers CSV S3 aux 6 tables du star schema RDS

6.2 Les 9 scripts SQL — détail

Script	Rôle	Idempotent
00_create_staging.sql	Crée les tables temporaires pour recevoir les CSV	Oui — DROP IF EXISTS
01_load_csv.sql	Charge les 4 CSV via COPY PostgreSQL depuis S3	Oui
02_populate_dim_date.sql	Génère toutes les dates 2024 (366 jours)	Oui
03_populate_dim_user.sql	Insère 10 000 utilisateurs avec SCD Type 2	Oui
04_populate_dim_merchant.sql	Insère 500 marchands + ligne spéciale -1	Oui
05_populate_dim_agency.sql	Insère 100 agences + ligne spéciale -1	Oui
07_load_transactions_csv.sql	Vérifie le chargement des 100 000 transactions	Oui
08_populate_fact_transactions.sql	INSERT dans fact_transactions + gestion anomalies	Oui
09_validation_checks.sql	Requêtes de validation post-chargement (FK = 0)	Oui

6.3 Gestion des anomalies (script 08)

sync_status	Nb lignes	Part	Traitement
SYNCED	94 923	94.92%	Transaction normale — chargée directement
LAGGING	1 912	1.91%	Retard de sync — include + flag is_lagging = TRUE
PENDING	1 616	1.62%	En cours — include + flag is_pending_sync = TRUE
CONFLICT	1 549	1.55%	Conflit nœuds — logique spéciale + is_conflict = TRUE

Idempotence garantie

Chaque script commence par DROP TABLE IF EXISTS. Relancer le pipeline deux fois produit exactement le même résultat. Cette propriété est critique pour les environnements de développement et les reprises sur erreur.

7. Infrastructure Docker — Reproductibilité Totale

7.1 Architecture Docker Compose

Service	Image Docker	Rôle	Port
postgres_dwh	postgres:16-alpine	Data Warehouse PostgreSQL	5432
etl	postgres:16-alpine	Runner ETL — 9 scripts SQL en séquence	—
metabase	metabase/metabase:latest	Dashboard BI	3000

7.2 Commandes de démarrage

```
cp .env.example .env
docker-compose up -d postgres_dwh
docker-compose --profile etl run --rm etl
docker-compose up -d metabase
# Ouvrir http://localhost:3000
```

8. Décisions Techniques (ADR-lite)

Décision	Choix retenu	Justification
PostgreSQL RDS vs Redshift	RDS PostgreSQL 16 ✓	Volume < 1M lignes — Redshift est surdimensionné et 3× plus cher.
Metabase vs QuickSight	Metabase ✓	Open source, gratuit. QuickSight coûte 18 \$/utilisateur/mois.
ETL SQL vs dbt	Scripts SQL ✓	100K lignes chargées en < 5 min. dbt ajoute de la complexité sans valeur au MVP.
eu-west-3 vs af-south-1	eu-west-3 Paris ✓	Plus proche de Nouakchott (4 000 km vs 7 000 km). Plus de services managés.
SSH vs SSM	SSM Session Manager ✓	Pas de port 22 exposé. Accès auditable via IAM. Recommandation AWS.

9. Estimation de Coût Mensuel

Service	Configuration	Coût/mois (USD)
RDS PostgreSQL 16	db.t3.medium	~55 \$
EC2 Metabase	t3.medium	~30 \$
EBS stockage gp3	80 Go	~6 \$
S3 staging	10 Go	~0,23 \$
Secrets Manager	1 secret	~0,40 \$
Data transfer	~10 Go/mois	~0,90 \$
TOTAL		~93 \$/mois

10. Sécurité & Bonnes Pratiques MVP

10.1 Mesures implémentées

- › Chiffrement in-transit : TLS 1.2+ obligatoire sur toutes les connexions RDS et Metabase.
- › Secrets Manager : le mot de passe RDS n'est jamais stocké en clair.
- › Least Privilege : Security Groups restrictifs — RDS accessible uniquement depuis l'EC2.
- › SSM Session Manager : accès EC2 sans port SSH 22 ouvert vers internet.
- › Backup automatique : RDS avec rétention 7 jours — point de restauration quotidien.

10.2 Limites connues du MVP

- › Authentification Metabase basique (login/password) — pas de SSO au MVP.
- › Pas de Row-Level Security PostgreSQL (prévu pour l'architecture At Scale).
- › Rotation des secrets manuelle — rotation automatique prévue à l'échelle.

11. Comparaison Early Stage vs At Scale

Critère	Early Stage (MVP)	At Scale
Coût mensuel	~93 \$	~241 \$
Volume max supporté	< 5M lignes	1 Md+ lignes
Utilisateurs BI simultanés	5–10	100+
Disponibilité	99%	99.9%
Authentification	Login/password Metabase	SSO Cognito SAML/OIDC
Sécurité PII	Basique (TLS)	RLS + Column Masking + Macie
ETL	Scripts SQL manuels	dbt Core + CI/CD
Stockage DWH	RDS PostgreSQL gp3	Redshift Serverless + S3 Parquet
Cache	Aucun	ElastiCache Redis (TTL 1h)
Latence p99 dashboard	< 3 secondes	< 1 seconde

12. Conclusion

L'architecture Early Stage de NAFAD PAY offre un rapport coût/valeur optimal pour le MVP : 93 \$/mois pour une infrastructure 100% reproductible, sécurisée et fonctionnelle.

Les trois schémas inclus dans ce document illustrent concrètement : (1) comment le flux réseau protège les données à chaque étape, (2) la logique de segmentation VPC qui rend RDS invisible depuis internet, et (3) le pipeline ETL idempotent qui garantit la reproductibilité du chargement des 100 000 transactions.

- › 100% reproductible : docker-compose up + run_all.sh suffit à tout démarrer.
- › Idempotence garantie : les scripts ETL peuvent être rejoués sans effets de bord.
- › Architecture justifiée : chaque choix AWS est argumenté avec des ADR-lite.
- › Coût maîtrisé : ~93 \$/mois, dimensionné exactement pour le volume MVP.
- › Sécurité documentée : TLS, Secrets Manager, Security Groups, SSM.